FieldBox.ai
Artificial Intelligence for Industry

EGC

Prédiction séquence-à-séquence de séries temporelles multivariées et déséquilibrées avec réseaux de neurones convolutifs unidimensionnels

Mercredi 27 Janvier 2021

Mehdi Elion

Sonia Tabti

Julien Budynek

Contexte et motivation

Données industrielles

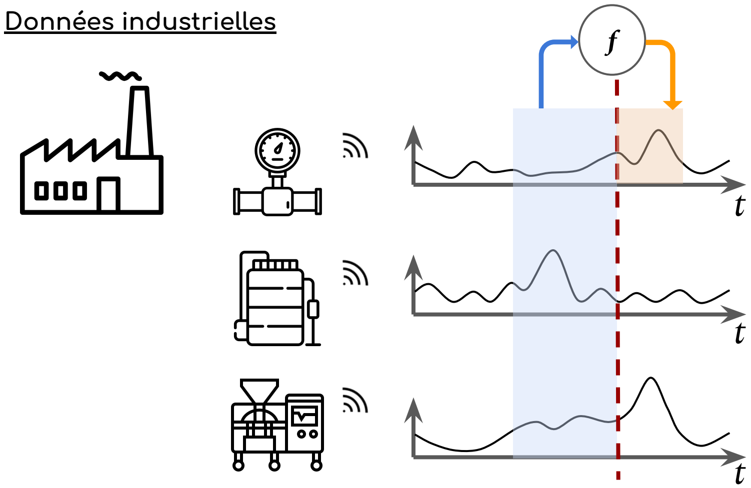

Évènements rares

- Pannes
- Anomalies, non conformités
- Baisses de qualité

Données déséquilibrées

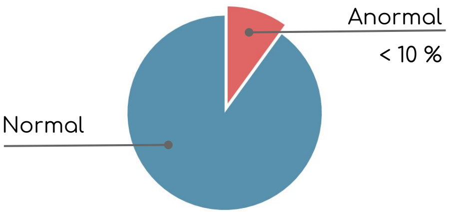

Augmentation de données

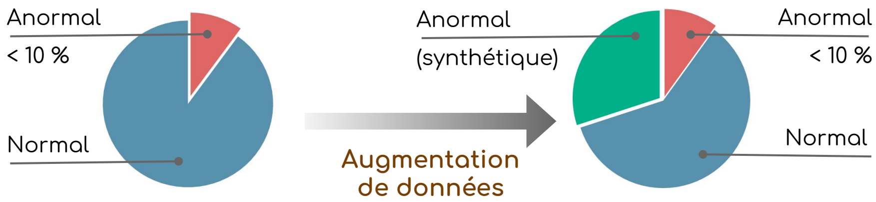

État de l'art

2002	• SMOTE (Synthetic Minority Oversampling Technique for classification)	Chawla et al.
2013	• SMOTE for Regression	Torgo et al
2017	• Adaptation de SMOTE-R à la prédiction de séries temporelles univariées à un pas dans le futur	Moniz et al
2020	• SMOTEST (Synthetic Minority Oversampling Technique for Sequence-To-sequence)	Notre proposition

FieldBox.ai
Artificial Intelligence for Industry

Approche proposée : SMOTEST

Sur-échantillonnage des données d'entraînement

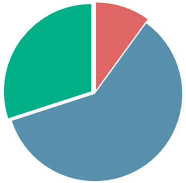

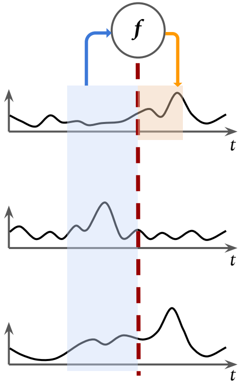

Séries temporelles multivariées

Séquence-à-séquence

CNN-1D

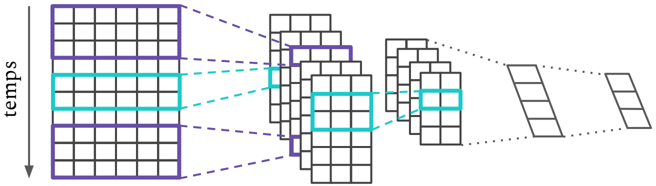

Algorithme de sur-échantillonnage

Illustration

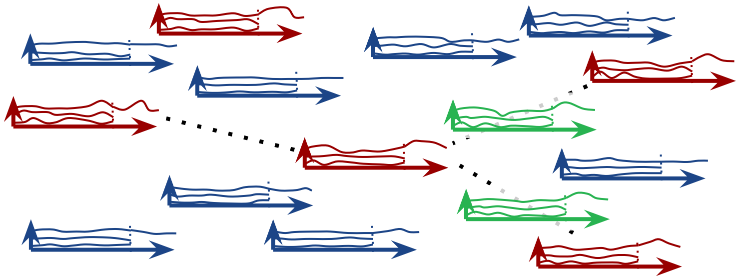

Exemple sur jeu de données synthétiques

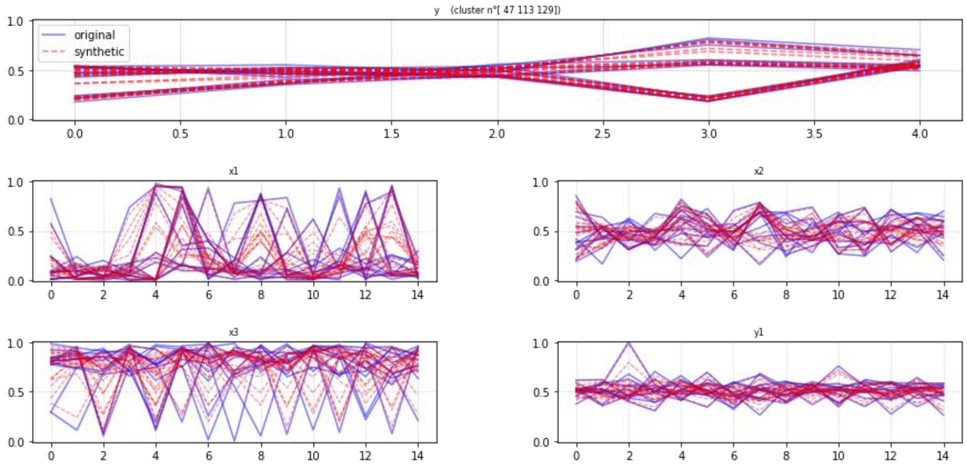

Approche proposée : SMOTEST

Sur-échantillonnage des données d'entraînement

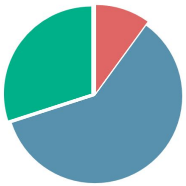

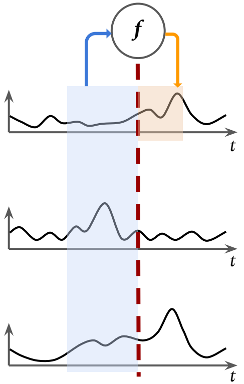

Séries temporelles multivariées

Séquence-à-séquence

CNN-1D

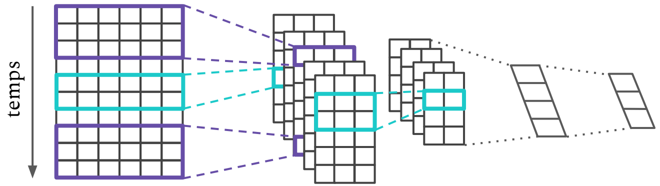

Algorithme de sur-échantillonnage

Algorithm 1 Algorithme de sur-échantillonnage

Require: n_g : nombre de cas synthétiques à générer par cas positif existant, k : nombre de voisins, G : générateur de nombres aléatoires, $\mathcal{D}_P = \{(X,Y) \mid \Phi(Y) \geq \theta\}$: ensemble des cas positifs

function GENSYNTHCASES($\mathcal{D}_P, n_g, k, G$)
    $\mathcal{D}_{gen} \leftarrow \varnothing$
    for all $(X,Y) \in \mathcal{D}_P$ **do**
        $NNS \leftarrow KNN(k, Y, \mathcal{D}_P \backslash \{(X,Y)\})$
        for $i = 1$ to n_g **do**
            $(X_{nn}, Y_{nn}) \leftarrow$ un cas choisi aléatoirement parmi *NNS*
            Initialiser (X_{new}, Y_{new}) pour contenir le $i^{\text{ème}}$ cas synthétique
            for all $s \in [\![1, n_X]\!]$ **do**
                $diff \leftarrow X_{nn}[:, s] - X[:, s]$
                $X_{new}[:, s] \leftarrow X[:, s] + G(0,1) \times diff$
            end for
            $d_1 \leftarrow DIST(X_{new}, X)$ ▷ distance euclidienne
            $d_2 \leftarrow DIST(X_{new}, X_{nn})$
            $Y_{new} \leftarrow \frac{d_2 Y + d_1 Y_{nn}}{d_1 + d_2}$
            $\mathcal{D}_{gen} \leftarrow \mathcal{D}_{gen} \cup \{(X_{new}, Y_{new})\}$
        end for
    end for
    return $\mathcal{D}_{gen}$
end function

Influence du mode de rééchantillonnage

<u>Données d'entraînement</u>

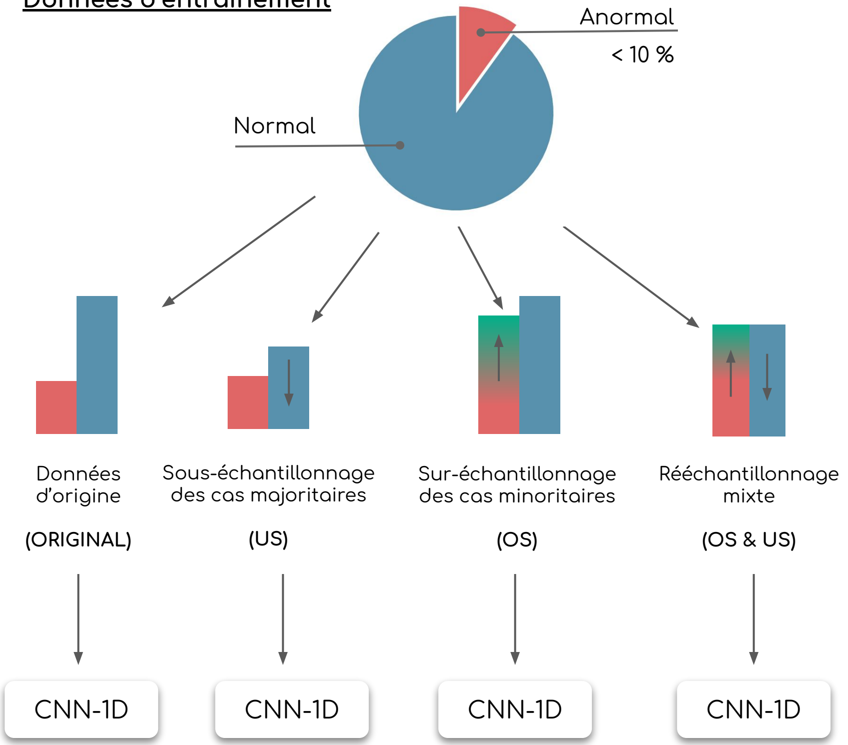

Résultats sur données synthétiques

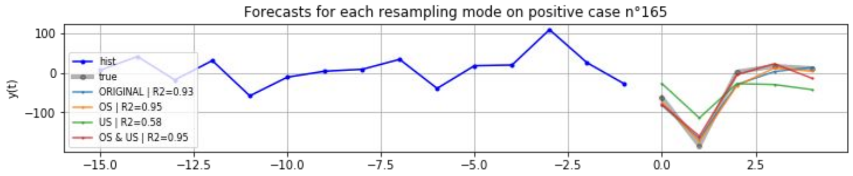

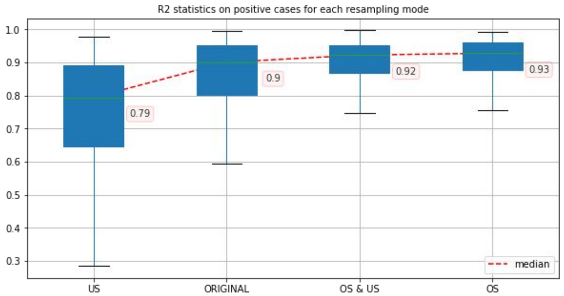

R^2 sur cas minoritaires

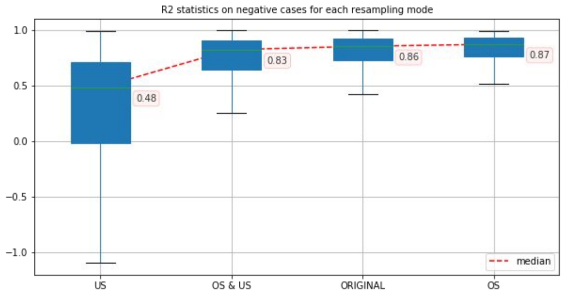

R^2 sur cas majoritaires

Influence de la distribution aléatoire

Fonctions forme $$f_n(x) = (x - 0.5)^n$$

Fonctions densité $$g_n(x) = f_n(x) / \int_0^1 f_n(t)\, dt$$

Synthèse de séquences $$\begin{cases} s_\lambda = \lambda s_0 + (1-\lambda) s_1 \\ \lambda \sim \mathcal{P}(g_n) \end{cases}$$

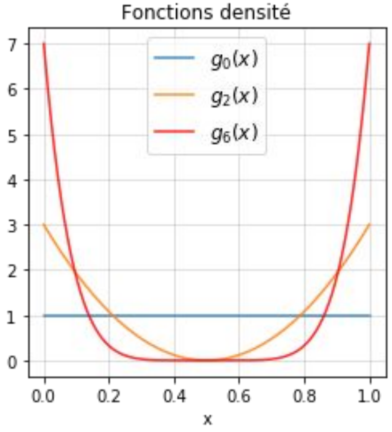

Données d'entraînement

↓

Sur-échantillonnage via g_n

↓

CNN-1D

Résultats sur données synthétiques

R2 sur cas minoritaires

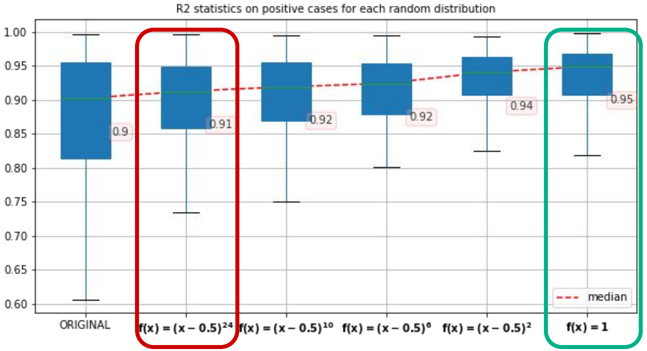

La distribution uniforme donne les meilleurs résultats

La réplication de données donne de moins bons résultats

R2 sur cas majoritaires

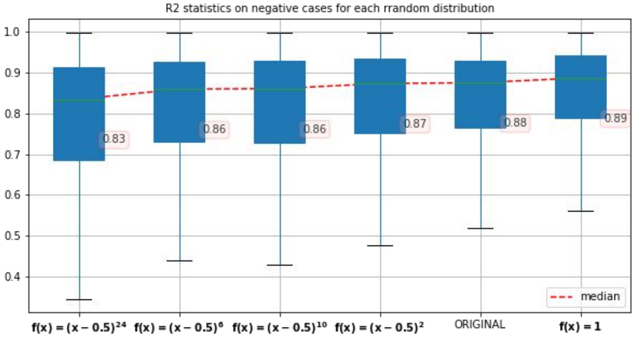

Expérience sur données industrielles

Problématique

- Contrôle qualité
- Variable cible à prédire : taux d'impureté
- Évènement rares à anticiper : augmentations brutales du taux d'impureté

Caractéristiques du jeu de données

- 10 variables (cible incluse)
- 90 points en entrées, 20 points en sortie
- 74000 échantillons
- 77% pour l'entraînement, 23% pour le test
- Envion 7% de cas rares

Résultats

- Amélioration des résultats sur cas rares
- Baisse de performance sur cas majoritaires

	Cas positifs		Cas négatifs	
	MAE	RMSE	MAE	RMSE
Original	0.36 ± 0.37	0.46 ± 0.43	$\mathbf{0.16 \pm 0.21}$	$\mathbf{0.19 \pm 0.23}$
SMOTEST	$\mathbf{0.34 \pm 0.35}$	$\mathbf{0.42 \pm 0.40}$	0.19 ± 0.21	0.22 ± 0.23

TAB. 1: Résultats sur les données industrielles de test ($w_{in} = 90, w_{out} = 20$). Les valeurs à gauche et à droite du signe $\pm$ correspondent resp. à la moyenne et l'écart type de l'erreur.

	TP	TN	FP	FN	bAcc	Rappel	Précision	Spécificité
Orig	3.87	89.88	3.22	3.03	76.31	56.08	54.58	96.54
OS + Unif	4.61	88.94	4.15	2.29	81.17	66.81	52.62	95.54

TAB. 6: Métriques de confusion sur le jeu de données industrielles (test).

Conclusions

Mode de rééchantillonnage

- Le sur-échantillonnage fournit les meilleurs résultats
- Le sous-échantillonnage rend le modèle sous-performant

Distribution aléatoire pour synthèse de séquences

- Une distribution uniforme fournit des résultats satisfaisants
- Une distribution proche de la duplication a tendance à rendre le modèle sous-performant

Données industrielles

- Augmentation des performances sur les cas d'intérêt

Perspectives

- Comparer d'autres méthodes d'augmentation de données
- Expérimenter sur plus de données industrielles
- Expérimenter avec d'autres modèles prédictifs (e.g. réseaux récurrents)
- Expérimenter sur d'autres types d'événements rares

Contacts

www.fieldbox.ai
melion@fieldbox.ai
fieldboxai/predict-rare-events-smotest

Annexes

Caractérisation des cas rares

Ensemble de cas $\mathcal{D} : (X, Y) \in \mathbb{R}^{w_{in} \times n} \times \mathbb{R}^{w_{out}}$

- w_{in} : taille des séquences d'entrée
- w_{out} : taille des séquences de sortie
- n : nombre de signaux d'entrée
- $X \in \mathbb{R}^{w_{in} \times n}$: signaux d'entrée d'un cas donné
- $Y \in \mathbb{R}^{w_{out}}$: signal de sortie associé à X

Caractérisation d'un cas $\Phi : \mathbb{R}^{w_{out}} \mapsto \mathbb{R}$

Exemple : augmentation maximale

$$\Phi\left((y(t+k))_{k \in 1, w_{out}}\right) = \max_{\substack{t \in 1, w_{out}-1 \\ \tau \in 1, w_{out}-t}} y(t+\tau) - y(t)$$

Ensemble des cas rares

$$\mathrm{D}_P = \{(X, Y) \in \mathcal{D} \mid \Phi(Y) \geq \theta\}$$

Evaluation

Métriques de régression

$$\mathrm{RMSE}(Y, \hat{Y}) = \sqrt{\frac{1}{w_{out}} \sum_{t=1}^{w_{out}} (Y[t] - \hat{Y}[t])^2}$$

$$\mathrm{MAE}(Y, \hat{Y}) = \frac{1}{w_{out}} \sum_{t=1}^{w_{out}} \left|Y[t] - \hat{Y}[t]\right|$$

Métriques de confusion

$$\mathrm{Rappel}(Y, \hat{Y}) = \frac{TP}{TP + FN}$$

$$\mathrm{Précision}(Y, \hat{Y}) = \frac{TP}{TP + FP}$$

$$\mathrm{Spécificité}(Y, \hat{Y}) = \frac{TN}{TN + FP}$$

$$\mathrm{bAcc}(Y, \hat{Y}) = \frac{1}{2}\left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP}\right)$$

Jeu de données synthétique

Caractéristiques du jeu de données

- 4 variables (cible incluse)
- 15 points en entrées, 5 points en sortie
- 9960 échantillons
- 70% pour l'entraînement, 30% pour le test
- Moins de 10% de cas rares

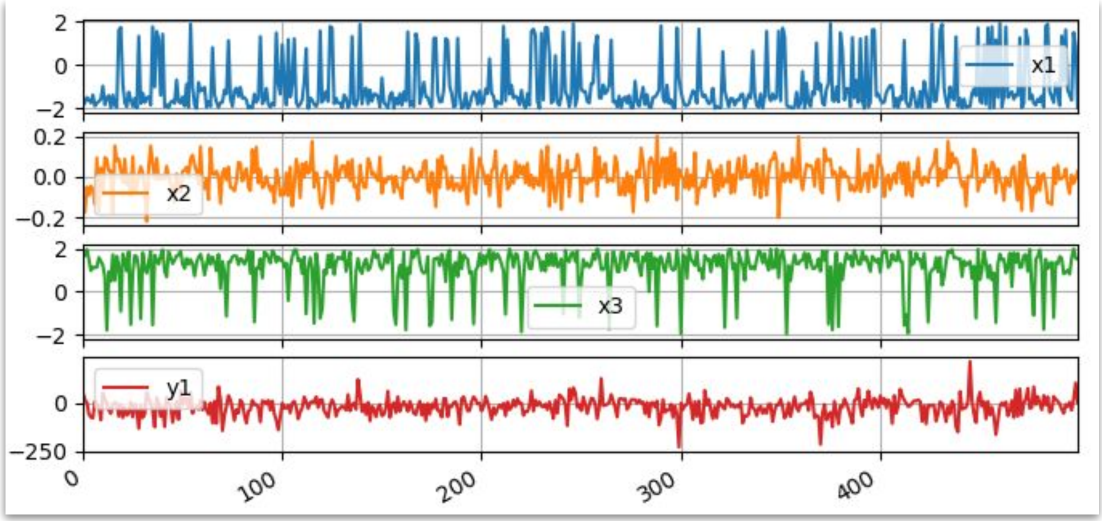

Influence du mode de rééchantillonnage

Données d'entraînement

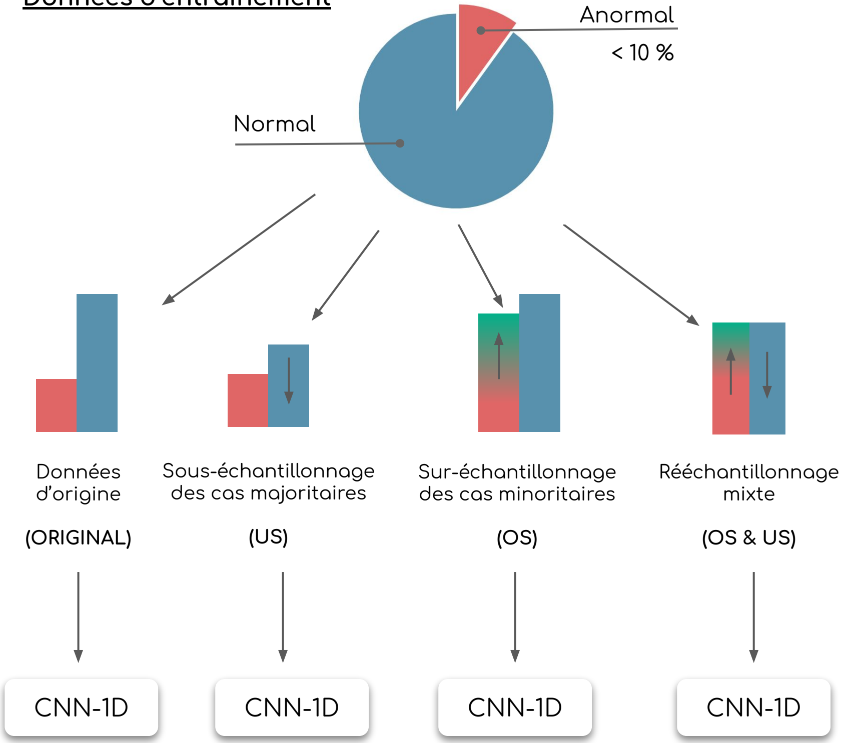

Résultats sur données synthétiques

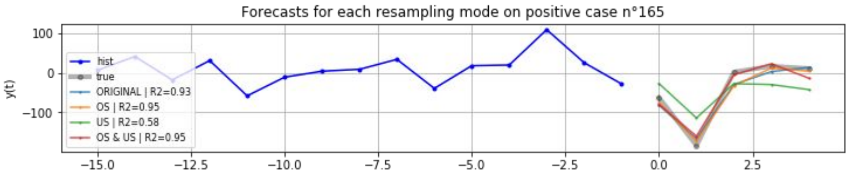

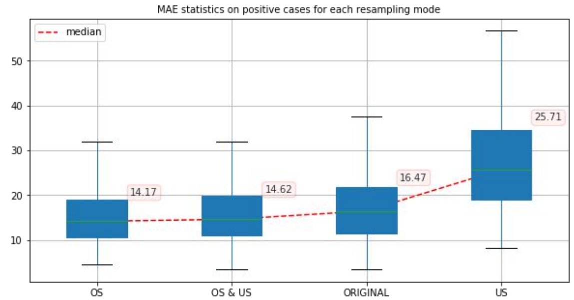

MAE sur cas minoritaires

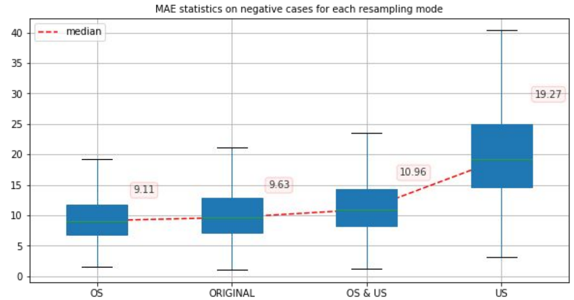

MAE sur cas majoritaires

FieldBox.ai
Artificial Intelligence for Industry

Influence du mode de rééchantillonnage

Données d'entraînement

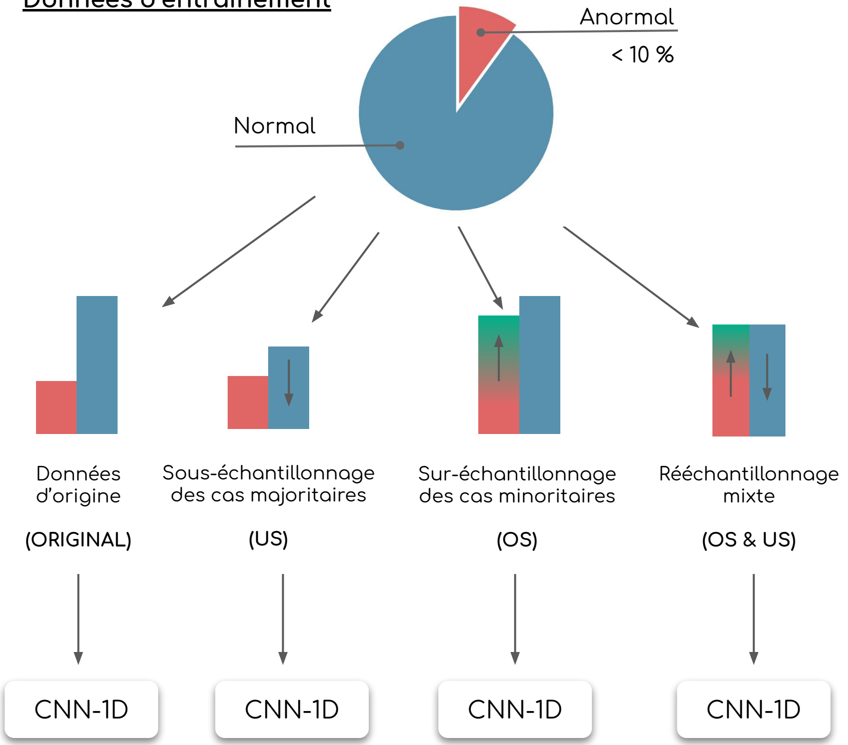

Résultats sur données synthétiques

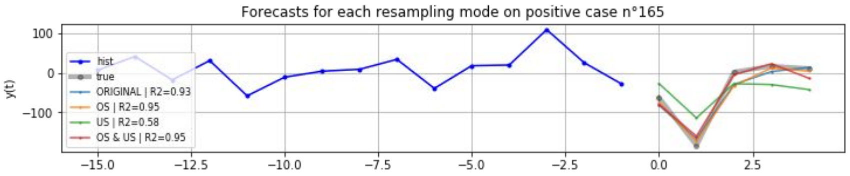

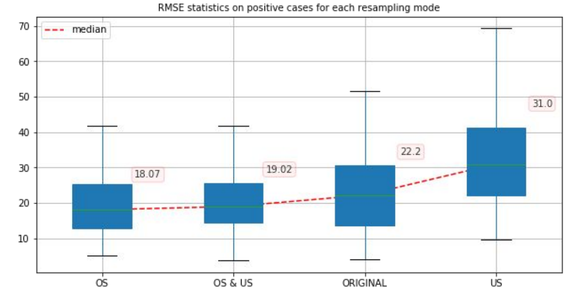

RMSE sur cas minoritaires

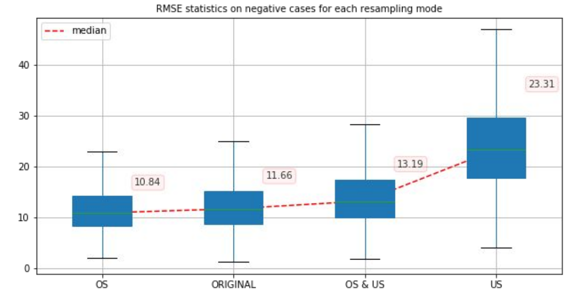

RMSE sur cas majoritaires

FieldBox.ai
Artificial Intelligence for Industry

Influence du mode de rééchantillonnage

Données d'entraînement

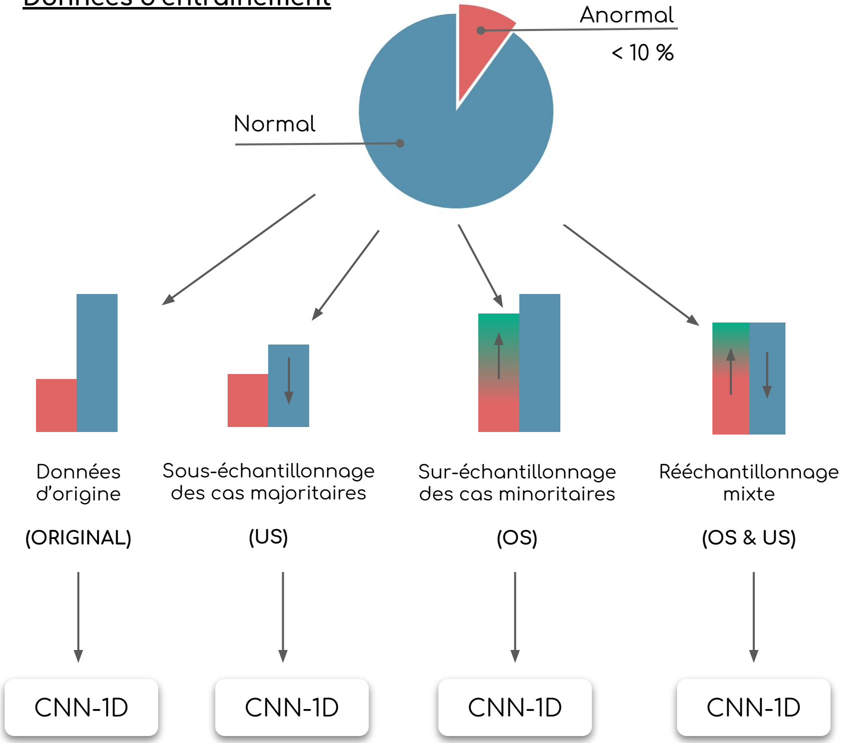

Résultats sur données synthétiques

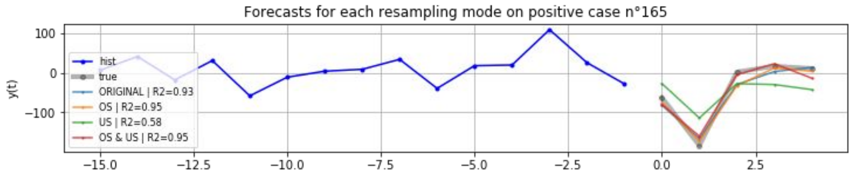

Métriques de confusion sur les données de test

	P	N	TP	TN	FP	FN	accuracy	recall	precision	specificity
ORIGINAL	8.43	91.57	4.15	90.37	1.2	4.28	94.52	49.21	77.5	98.69
OS	8.43	91.57	5.22	89.97	1.61	3.21	95.18	61.9	76.47	98.25
US	8.43	91.57	3.88	85.69	5.89	4.55	89.57	46.03	39.73	93.57
OS & US	8.43	91.57	5.55	89.36	2.21	2.88	94.92	65.87	71.55	97.59

Métriques de confusion sur les données d'entraînement

	P	N	TP	TN	FP	FN	accuracy	recall	precision	specificity
ORIGINAL	7.86	92.14	4.35	91.32	0.82	3.51	95.67	55.29	84.17	99.11
OS	47.74	52.26	41.39	51.51	0.75	6.34	92.9	86.71	98.21	98.56
US	50	50	31.66	48.54	1.46	18.34	80.2	63.32	95.59	97.08
OS & US	48.03	51.97	42.2	51.01	0.96	5.83	93.21	87.86	97.78	98.15

FieldBox.ai
Artificial Intelligence for Industry

Influence de la distribution aléatoire

Fonctions forme $$f_n(x) = (x - 0.5)^n$$

Fonctions densité $$g_n(x) = f_n(x) / \int_0^1 f_n(t)\,dt$$

Synthèse de séquences $$\begin{cases} s_\lambda = \lambda s_0 + (1-\lambda) s_1 \\ \lambda \sim \mathcal{P}(g_n) \end{cases}$$

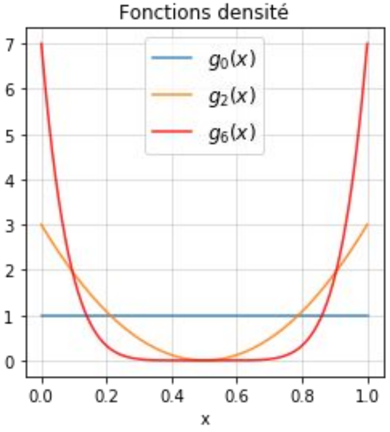

Données d'entraînement

↓

Sur-échantillonnage via g_n

↓

CNN-1D

Résultats sur données synthétiques

MAE sur cas minoritaires

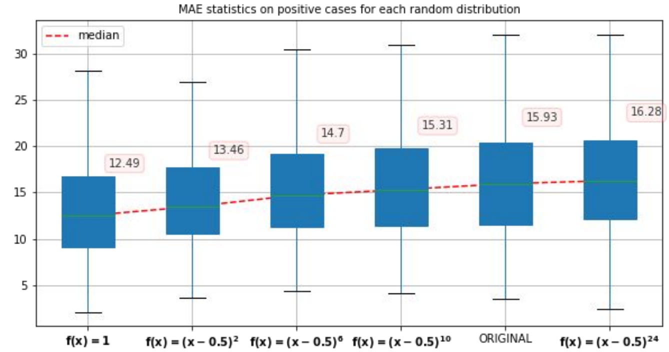

MAE sur cas majoritaires

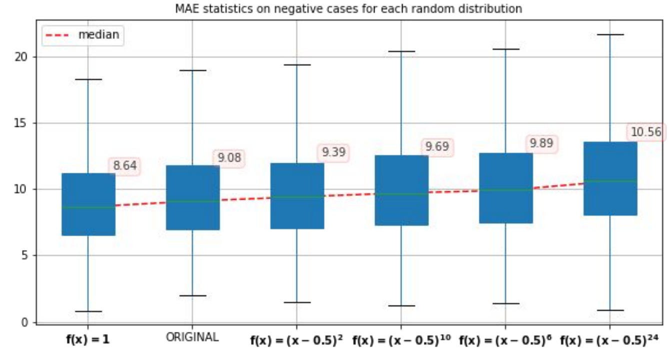

Influence de la distribution aléatoire

Fonctions forme $$f_n(x) = (x - 0.5)^n$$

Fonctions densité $$g_n(x) = f_n(x) / \int_0^1 f_n(t)\, dt$$

Synthèse de séquences $$\begin{cases} s_\lambda = \lambda s_0 + (1-\lambda) s_1 \\ \lambda \sim \mathcal{P}(g_n) \end{cases}$$

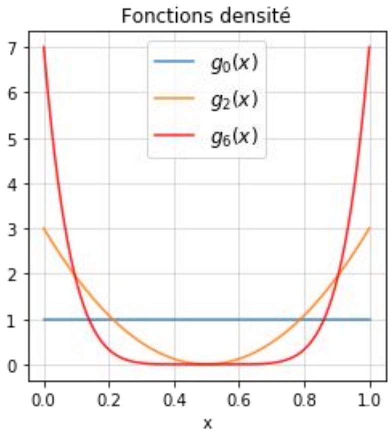

Données d'entraînement

↓

Sur-échantillonnage via g_n

↓

CNN-1D

Résultats sur données synthétiques

RMSE sur cas minoritaires

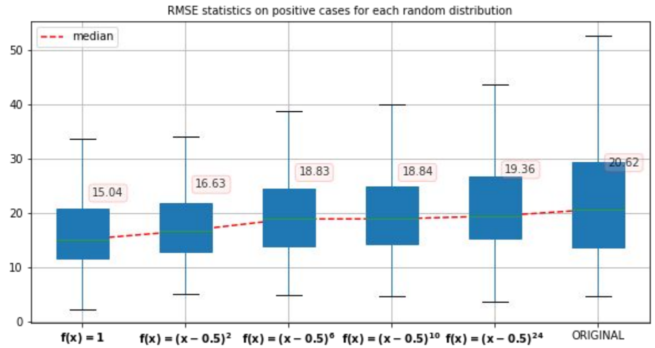

RMSE sur cas majoritaires

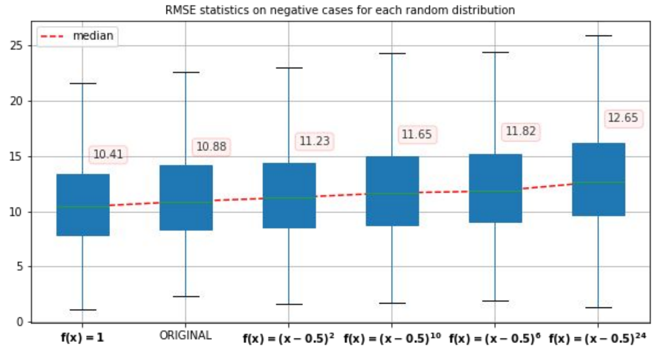

Influence de la distribution aléatoire

Fonctions forme $$f_n(x) = (x - 0.5)^n$$

Fonctions densité $$g_n(x) = f_n(x) / \int_0^1 f_n(t)\, dt$$

Synthèse de séquences $$\begin{cases} s_\lambda = \lambda s_0 + (1 - \lambda) s_1 \\ \lambda \sim \mathcal{P}(g_n) \end{cases}$$

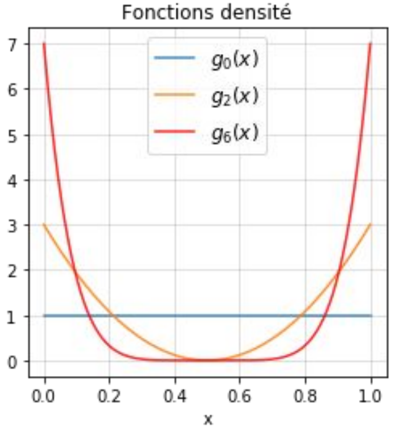

Données d'entraînement

↓

Sur-échantillonnage via g_n

↓

CNN-1D

Résultats sur données synthétiques

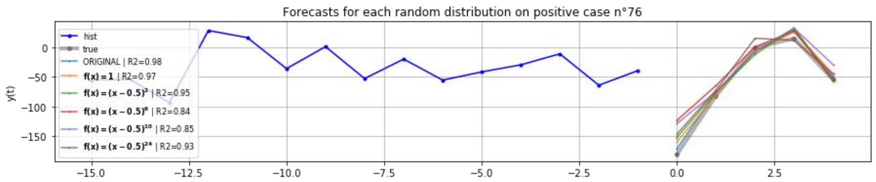

Métriques de confusion sur les données de test

Original and Resampled Datasets	P	N	TP	TN	FP	FN	accuracy	recall	precision	specificity
ORIGINAL	8.43	91.57	3.75	90.43	1.14	4.68	94.18	44.44	76.71	98.76
$f(x) = 1$	8.43	91.57	5.55	90.5	1.07	2.88	96.05	65.87	83.84	98.83
$f(x) = (x - 0.5)^2$	8.43	91.57	5.42	90.17	1.4	3.01	95.59	64.29	79.41	98.47
$f(x) = (x - 0.5)^6$	8.43	91.57	5.82	89.77	1.81	2.61	95.59	69.05	76.32	98.03
$f(x) = (x - 0.5)^{10}$	8.43	91.57	4.75	90.7	0.87	3.68	95.45	56.35	84.52	99.05
$f(x) = (x - 0.5)^{24}$	8.43	91.57	4.62	90.77	0.8	3.81	95.38	54.76	85.19	99.12

Métriques de confusion sur les données d'entraînement

Original and Resampled Datasets	P	N	TP	TN	FP	FN	accuracy	recall	precision	specificity
ORIGINAL	7.86	92.14	4.65	91.05	1.09	3.21	95.7	59.12	81	98.82
$f(x) = 1$	47.94	52.06	41.02	51.42	0.63	6.92	92.44	85.56	98.48	98.78
$f(x) = (x - 0.5)^2$	47.9	52.1	41.38	51.5	0.59	6.52	92.88	86.39	98.58	98.86
$f(x) = (x - 0.5)^6$	48.06	51.94	42.68	50.86	1.08	5.38	93.54	88.81	97.54	97.93
$f(x) = (x - 0.5)^{10}$	47.99	52.01	39.42	51.3	0.71	8.57	90.72	82.15	98.24	98.64
$f(x) = (x - 0.5)^{24}$	48.02	51.98	40.78	51.04	0.94	7.24	91.82	84.93	97.75	98.19